СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ 3

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ 4

ВВЕДЕНИЕ 5

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ 8
1.1 Когнитивные предубеждения: теоретические основания 8
1.1.1 Программа эвристик и предубеждений Канемана и Тверски 8
1.1.2 Типология когнитивных предубеждений: вероятностные, логические, индуктивные 8
1.1.3 Нормативные стандарты рассуждения и отклонения от них 9
1.2 Анализ проблемы: когнитивные предубеждения в LLM 9
1.2.1 Природа предубеждений в языковых моделях: memorization vs. emergent bias 9
1.2.2 Проблема контаминации обучающих данных 10
1.2.3 Ограничения существующих подходов к тестированию 10
1.3 Обзор смежных исследований 10
1.3.1 Ошибка конъюнкции и эвристика репрезентативности в LLM 10
1.3.2 Задача выбора карточек Уэйсона в LLM 11
1.3.3 Индуктивное открытие правил и задача 2-4-6 в LLM 11
1.3.4 Сравнительные бенчмарки когнитивных предубеждений в LLM 12
1.4 Образ решения: исследовательские гипотезы 12
1.4.1 Гипотеза об универсальности предубеждений 12
1.4.2 Гипотеза о масштабировании и снижении предубеждений 12
1.4.3 Гипотеза о спектральной природе предубеждений 12
1.4.4 Гипотеза о демографическом токен-bias 13
1.5 Требования к экспериментальному исследованию 13
1.5.1 Требования к датасетам и контролю контаминации 13
1.5.2 Требования к метрикам и статистическому выводу 13
1.5.3 Требования к набору тестируемых моделей 13

2 ДИЗАЙН И ПРОВЕДЕНИЕ ЭКСПЕРИМЕНТОВ 15
2.1 Обзор экспериментального фреймворка 15
2.1.1 Три парадигмы как единый спектр 15
2.1.2 Общие принципы дизайна 15
2.2 Эксперимент 1: Ошибка конъюнкции (Задача Линды) 15
2.2.1 Обоснование выбора парадигмы 15
2.2.2 Проблема контаминации и подходы к её решению 16
2.2.3 Конструкция датасета: биографические виньетки 16
2.2.4 Демографические подстановки и факториальный дизайн 16
2.2.5 Протокол эксперимента и промпт-структура 17
2.2.6 Метрики: бинарная точность, тест МакНемара, Severity of Bias 17
2.2.7 Результаты и анализ 17
2.2.8 Выводы по эксперименту 1 18
2.3 Эксперимент 2: Задача выбора карточек Уэйсона 18
2.3.1 Обоснование выбора парадигмы 18
2.3.2 Конструкция стимульных датасетов: четыре контентных условия 19

2.3.3 Протокол перестановок порядка карточек ... 19
2.3.4 Промпт-условия ... 19
2.3.5 Метрики ... 20
2.3.6 Результаты и анализ ... 20
2.3.7 Выводы по эксперименту 2 ... 21
2.4 Эксперимент 3: Задача открытия правила 2-4-6 ... 22
2.4.1 Обоснование выбора парадигмы ... 22
2.4.2 Конструкция датасета правил: пять таксономических категорий ... 22
2.4.3 Многоходовой диалоговый протокол ... 22
2.4.4 Промпт-условия: Baseline и Adaptive ... 22
2.4.5 Метрики качества гипотез ... 23
2.4.6 Результаты и анализ ... 23
2.4.7 Выводы по эксперименту 3 ... 24
2.5 Сквозной анализ: три парадигмы, девять моделей ... 24
2.5.1 Сравнительная таблица результатов по всем экспериментам ... 24
2.5.2 Проверка гипотез о масштабировании и внутрисемейный парадокс ... 24
2.5.3 Проверка гипотезы о спектральной природе предубеждений ... 25
2.5.4 Итоги: Proof-of-Concept фреймворка оценки когнитивных предубеждений ... 25

ЗАКЛЮЧЕНИЕ ... 27

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ ... 27

А РУКОВОДСТВО ПО ИСПОЛЬЗОВАНИЮ ШАБЛОНА ... 30

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

API — программный интерфейс приложения (Application Programming Interface)

CoT — цепочка рассуждений (Chain-of-Thought)

FDR — уровень ложных открытий (False Discovery Rate)

IOU — пересечение по объединению (Intersection over Union)

LLM — большая языковая модель (Large Language Model)

MBI — индекс предубеждения соответствия (Matching Bias Index)

CBR — доля предубеждения подтверждения (Confirmation Bias Rate)

EMA — ожидаемая точность метрики (Expected Metric Accuracy)

WST — задача выбора карточек Уэйсона (Wason Selection Task)

ВКР — выпускная квалификационная работа

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Большая языковая модель — нейросетевая модель на основе трансформерной архитектуры, обученная на больших текстовых корпусах и способная генерировать связный текст

Задача 2-4-6 — психологическая парадигма для исследования индуктивного открытия правил, в которой испытуемый угадывает скрытое правило, предлагая числовые тройки и получая бинарную обратную связь

Задача выбора карточек Уэйсона — психологическая парадигма для исследования условного рассуждения и ошибок логического вывода, в которой испытуемый выбирает карточки, необходимые для проверки условного правила

Когнитивное предубеждение — устойчивое систематическое отклонение от нормативных стандартов вероятностного или логического рассуждения

Контаминация обучающих данных — явление, при котором тестовые задачи присутствуют в обучающем корпусе модели, что искажает оценку её реальных когнитивных способностей

Ошибка конъюнкции — когнитивное предубеждение, при котором вероятность конъюнкции двух событий оценивается как более высокая, чем вероятность одного из них

Предубеждение подтверждения — когнитивное предубеждение, при котором агент предпочитает искать и принимать информацию, подтверждающую имеющуюся гипотезу, а не опровергающую её

Эвристика репрезентативности — когнитивная стратегия оценки вероятности события по степени его соответствия типичному прототипу без учёта базовых вероятностей

ВВЕДЕНИЕ

Актуальность темы исследования. Большие языковые модели (LLM) всё активнее встраиваются в системы поддержки принятия решений: от медицинской диагностики и юридического анализа до финансового консультирования и автоматизированного обучения [1]. По мере того как область применения подобных систем расширяется, принципиальное значение приобретает вопрос об их когнитивной надёжности: способны ли модели рассуждать нормативно корректно, или же они воспроизводят систематические ошибки, характерные для человеческого мышления? Когнитивные предубеждения — устойчивые отклонения от нормативных стандартов вероятностного и логического рассуждения — давно являются предметом исследований в психологии и поведенческой экономике [2]. С появлением масштабных языковых моделей, обученных на огромных корпусах текстов, порождённых людьми, закономерно возникает гипотеза о том, что подобные предубеждения могут быть имплицитно усвоены в ходе обучения и проявляться при решении задач, требующих строгого вероятностного или логического мышления.

Несмотря на растущий массив литературы, посвящённой рациональности LLM [3–5], большинство существующих работ сосредоточено на отдельных задачах или узком наборе моделей, не рассматривая предубеждения как феномен, существующий на спектре — от вероятностного суждения к классическому логическому рассуждению и далее к индуктивному открытию правил. Настоящая работа восполняет этот пробел, предлагая систематическое сравнительное исследование трёх парадигм когнитивной психологии на девяти современных языковых моделях.

Степень разработанности проблемы. Первые систематические исследования когнитивных предубеждений в LLM появились в 2023–2024 годах. Binz и Schulz [3] показали, что GPT-3 демонстрирует эффекты репрезентативности и предвзятости подтверждения на классических задачах из программы эвристик и предубеждений Канемана и Тверски. Suri и соавторы [4] расширили эту линию, исследовав эффект фрейминга и ошибку конъюнкции в GPT-4. Macmillan-Scott и Musolesi [5] провели масштабный бенчмарк нескольких моделей на задаче Уэйсона. Тем не менее ни одна из указанных работ не рассматривает все три парадигмы — конъюнктивную ошибку, задачу выбора карточек и задачу открытия правила 2-4-6 — в едином экспериментальном дизайне и не вводит непрерывных метрик, позволяющих измерить силу предубеждения за пределами бинарной классификации ответов.

Цель и задачи исследования. Цель настоящей работы — систематически измерить и сравнить когнитивные предубеждения в современных LLM на трёх классических психологических парадигмах, охватывающих различные типы рассуждения: вероятностное суждение, условная логика и индуктивное открытие правил.

Для достижения данной цели поставлены следующие задачи:

- провести анализ существующих подходов к изучению когнитивных предубеждений в LLM и выявить методологические ограничения предшествующих работ;
- разработать экспериментальный дизайн для трёх парадигм — задачи Линды (ошибка конъюнкции), задачи выбора карточек Уэйсона и задачи открытия правила 2-4-6 — с контролем за контаминацией обучающих данных;
- сформировать оригинальные датасеты для каждого эксперимента, обеспечивающие структурное единообразие и отсутствие пересечения с обучающими корпусами;
- провести эксперименты на девяти современных языковых моделях, охватывающих широкий спектр архитектур, размеров и провайдеров;
- ввести и апробировать непрерывную метрику силы предубеждения (Severity of Bias) как альтернативу бинарной классификации ошибок;
- сравнить поведение моделей в трёх парадигмах и проверить гипотезу о масштабировании как факторе снижения предубеждений;
- на основании полученных результатов сформулировать рекомендации по выбору и оценке LLM для приложений, требующих нормативно корректного рассуждения.

Объект и предмет исследования. Объектом исследования являются большие языковые модели как системы рассуждения. Предметом исследования служат когнитивные предубеждения в ответах LLM на задачи из трёх психологических парадигм: ошибка конъюнкции, предвзятость подтверждения в условной логике и предвзятость подтверждения в индуктивном открытии правил.

Научная новизна. Научная новизна работы определяется следующими результатами:

– впервые проведено сравнительное исследование трёх классических парадигм когнитивной психологии — ошибки конъюнкции, задачи Уэйсона и задачи 2-4-6 — в едином экспериментальном дизайне на одном и том же наборе из девяти моделей, что позволяет рассматривать предубеждение как единый феномен на спектре типов рассуждения;
– введена оригинальная непрерывная метрика Severity of Bias, основанная на самооценке уверенности модели и позволяющая обнаруживать токен-предубеждение в случаях, когда бинарная метрика демонстрирует потолок точности;
– разработан оригинальный датасет из 110 биографических виньеток для задачи Линды с систематической факториальной подстановкой демографических переменных, что обеспечивает контроль за конфаундерами нарративного стиля;
– введено условие «фантастических социальных контрактов» в задаче Уэйсона, позволяющее диссоциировать эффект знакомости содержания от эффекта деонтической структуры, что, насколько известно автору, ранее не реализовывалось в исследованиях LLM;
– обнаружен и описан внутрисемейный парадокс масштаба в семействах моделей Gemma и Qwen: меньшая модель демонстрирует более низкий уровень предубеждения, чем большая модель того же семейства.

Практическая значимость. Результаты исследования имеют непосредственное прикладное значение в нескольких направлениях. Во-первых, разработанный фреймворк тестирования когнитивных предубеждений может применяться при выборе языковой модели для систем поддержки принятия решений, где критична нормативная корректность рассуждения — в частности, в медицинской диагностике, юридическом анализе и финансовом консультировании. Во-вторых, введённая метрика Severity of Bias предоставляет более тонкий инструмент оценки, чем бинарная точность, что позволяет проводить сравнение моделей в условиях, когда все они достигают высокой точности по бинарной метрике. В-третьих, выявленные различия в поведении моделей на различных типах задач позволяют формулировать рекомендации по prompt engineering для снижения предубеждений. Полученные датасеты и экспериментальный код публикуются в открытом доступе в целях воспроизводимости исследований.

Методологическая основа. Исследование опирается на классические парадигмы когнитивной психологии [6–8], адаптированные для тестирования языковых моделей. В качестве статистических инструментов используются точный тест МакНемара для согласованных пар [9], парный t-тест, критерий Уилкоксона и процедура Бенджамини-Хохберга для контроля частоты ложных открытий [10]. Для оценки качества гипотез в задаче 2-4-6 применяется метрика расширенного пересечения по объединению (IOU) на основе метода Монте-Карло, впервые предложенная Banatt и соавторами [11].

Апробация результатов. Основные результаты исследования были представлены на кандидатском экзамене в AI Talent Hub ИТМО (январь 2026 г.). Работа выполнена в рамках научно-исследовательской практики магистерской программы по направлению искусственный интеллект под руководством Ильи Макарова.

Структура работы. Работа состоит из введения, трёх глав, заключения, списка использованных источников и приложений.

В *первой главе* проводится анализ предметной области: рассматриваются теоретические основы когнитивных предубеждений, анализируется проблема их воспроизведения в LLM в соответствии с текущим состоянием, выполняется обзор смежных работ и формулируются исследовательские гипотезы.

Во *второй главе* описывается дизайн экспериментов: обосновывается выбор парадигм, представлены оригинальные датасеты, промпт-условия, протестированные модели и система метрик; приводятся результаты экспериментов и их анализ.

В *третьей главе* предлагается архитектура практического инструмента для оценки когнитивных предубеждений в LLM на основе полученных экспериментальных результатов.

В *заключении* подводятся итоги работы, формулируются основные выводы и намечаются направления дальнейших исследований.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Когнитивные предубеждения: теоретические основания

1.1.1 Программа эвристик и предубеждений Канемана и Тверски

Систематическое изучение когнитивных предубеждений как научной проблемы восходит к серии работ Амоса Тверски и Даниэля Канемана, опубликованных в 1970–1980-х годах [6; 12]. В основе их исследовательской программы лежало наблюдение о том, что люди при принятии решений в условиях неопределённости систематически нарушают нормы рационального поведения, постулируемые теорией ожидаемой полезности и математической теорией вероятностей. Вместо точного байесовского обновления убеждений человек использует упрощённые ментальные операции — эвристики, — которые, будучи когнитивно экономными, порождают предсказуемые и воспроизводимые ошибки суждения.

Канеман и Тверски описали три основные эвристики, лежащие в основе широкого класса предубеждений [2]. *Эвристика репрезентативности* состоит в оценке вероятности события по степени его соответствия типичному прототипу или нарративному шаблону без учёта базовых вероятностей. *Эвристика доступности* связана с оценкой вероятности через лёгкость, с которой соответствующие примеры извлекаются из памяти. *Эвристика якорения и корректировки* предполагает оценку числовых величин через корректировку от некоторого начального значения, причём корректировка систематически оказывается недостаточной.

Для настоящего исследования наиболее релевантна эвристика репрезентативности, поскольку именно она лежит в основе ошибки конъюнкции — центральной парадигмы первого эксперимента. Согласно этой эвристике, конъюнктивный вариант ответа кажется более вероятным, если он нарративно согласуется с описанием персонажа, даже если формальные законы теории вероятностей однозначно исключают такой вывод.

Теоретическим обобщением эвристической программы стала двухсистемная модель, разработанная Канеманом [2]: *Система 1* работает быстро, автоматически, ассоциативно и не требует осознанных усилий; *Система 2* — медленно, последовательно, по правилам и с затратами когнитивных ресурсов. Большинство когнитивных предубеждений возникает именно тогда, когда Система 1 генерирует ответ, который Система 2 принимает без достаточной проверки. Эта модель имеет прямые следствия для интерпретации поведения языковых моделей: авторегрессионная генерация токенов по своей природе ближе к Системе 1, тогда как явное пошаговое рассуждение (chain-of-thought) представляет собой попытку эмулировать Систему 2 [13].

1.1.2 Типология когнитивных предубеждений: вероятностные, логические, индуктивные

Для целей настоящего исследования когнитивные предубеждения классифицируются по типу нарушаемой нормы рассуждения. Эта классификация непосредственно определяет выбор трёх экспериментальных парадигм и позволяет рассматривать их как единый спектр, а не как изолированные явления.

Вероятностные предубеждения возникают при нарушении аксиом теории вероятностей. Наиболее известный пример — ошибка конъюнкции [6]: оценка $P(A \cap B) > P(A)$, что математически невозможно. К этой же категории относятся пренебрежение базовыми вероятностями (base-rate neglect), ошибка игрока и эффект фрейминга [12]. Общим механизмом является подмена вероятностного суждения оценкой нарративной правдоподобности.

Логические предубеждения проявляются при нарушении норм дедуктивного вывода. Задача выбора карточек Уэйсона [7] является классическим инструментом их диагностики: правильный ответ требует применения правила modus tollens ($P \rightarrow Q$, $\neg Q \Rightarrow \neg P$), тогда как большинство испытуемых выбирают подтверждающие карточки вместо фальсифицирующих. Предубеждение подтверждения [14] — тенденция искать и интерпретировать информацию в пользу имеющейся гипотезы — является общим механизмом как для логических, так и для индуктивных предубеждений.

Индуктивные предубеждения возникают при нарушении нормативных стандартов формирования и

пересмотра гипотез. Задача 2-4-6 Уэйсона [8] демонстрирует, что люди систематически тестируют тройки, согласующиеся с текущей гипотезой, вместо того чтобы искать опровергающие примеры. Байесовская норма предписывает максимизацию информационной ценности теста, что требует проверки именно тех случаев, которые могут фальсифицировать гипотезу [15].

Три парадигмы настоящего исследования образуют прогрессирующий спектр сложности рассуждения: от одношагового вероятностного суждения к дедуктивному анализу условных правил и далее к многоходовому итеративному открытию правил. Это позволяет исследовать, является ли предубеждение LLM единым феноменом или варьируется в зависимости от типа требуемого рассуждения.

1.1.3 Нормативные стандарты рассуждения и отклонения от них

Под нормативным стандартом в настоящей работе понимается критерий, относительно которого ответ модели однозначно классифицируется как правильный или ошибочный. Для каждой из трёх парадигм такой стандарт задаётся формально.

В задаче ошибки конъюнкции нормативный ответ определяется аксиомой теории вероятностей: $P(A \cap B) \leq P(A)$ для любых событий A и B. Выбор конъюнктивного варианта однозначно является ошибкой вне зависимости от нарративного контекста.

В задаче выбора карточек нормативный ответ определяется правилом материальной условности: для проверки истинности правила «если P, то Q» необходимо и достаточно перевернуть карточки P и $\neg Q$ [7]. Карточки $\neg P$ и Q не могут опровергнуть правило и поэтому не должны выбираться.

В задаче 2-4-6 нормативный стандарт является более сложным: критерием успеха служит финальная гипотеза модели, а не конкретная последовательность тестов. Оценка производится через метрику пересечения по объединению (IOU) над случайной выборкой троек, что позволяет сравнивать гипотезы, записанные в различных синтаксических формах, по их экстенсиональной эквивалентности [11].

1.2 Анализ проблемы: когнитивные предубеждения в LLM

1.2.1 Природа предубеждений в языковых моделях: memorization vs. emergent bias

Принципиальный методологический вопрос при тестировании LLM на когнитивных задачах состоит в интерпретации наблюдаемых ошибок. Существуют два конкурирующих объяснения того, почему языковая модель может демонстрировать ответ, характерный для когнитивного предубеждения.

Согласно гипотезе *memorization*, модель воспроизводит правильный или ошибочный ответ, потому что видела данную конкретную задачу или её близкие аналоги в обучающем корпусе. Задача Линды, задача Уэйсона и задача 2-4-6 входят в число наиболее цитируемых психологических экспериментов и с высокой вероятностью представлены в корпусах, на которых обучены современные LLM. Если модель демонстрирует правильный ответ на каноническую формулировку, это не обязательно свидетельствует о подлинном вероятностном рассуждении — она могла просто запомнить ответ [16]. Симметрично, воспроизведение человекоподобной ошибки на знакомой задаче может отражать memorization паттернов ошибок из психологических текстов, а не возникновение bias в процессе рассуждения.

Согласно гипотезе *emergent bias*, предубеждения возникают как следствие самой природы обучения на человеческих текстах: модель усваивает не только факты, но и типичные паттерны человеческого рассуждения, включая систематические отклонения от нормативных стандартов. В этом случае предубеждения должны воспроизводиться на новых, контаминационно чистых стимулах, структурно аналогичных классическим задачам.

Binz и Schulz [3] продемонстрировали свидетельства в пользу гипотезы memorization: GPT-3 решал каноническую версию задачи Уэйсона правильно, но немедленно давал ошибочные ответы при изменении порядка карточек. Dasgupta и соавторы [17], напротив, показали, что на специально сконструированных деконтаминированных стимулах крупные модели воспроизводят человекоподобные контент-эффекты, что указывает на emergent bias. Настоящее исследование придерживается осторожной позиции: контаминация контролируется через генерацию оригинальных датасетов, однако разграничение memorization и emergent bias

не является первичной целью — целью является измерение итогового поведения модели вне зависимости от механизма его порождения.

1.2.2 Проблема контаминации обучающих данных

Контаминация обучающих данных (training data contamination) — одна из центральных методологических проблем при оценке когнитивных способностей LLM [16]. Её специфика в контексте когнитивных задач состоит в следующем: в отличие от математических бенчмарков, где контаминация ведёт к завышению точности, в когнитивных задачах контаминация может давать как завышение (если модель запоминает правильный нормативный ответ), так и занижение (если модель запоминает человекоподобный ошибочный паттерн из психологических учебников).

Предшествующие исследования предлагали различные стратегии борьбы с контаминацией. Suri и соавторы [4] разработали оригинальный промпт с новым сценарием (посетительница кафе), исключающим прямое совпадение с текстом задачи Линды. Jiang и соавторы [18] предложили фреймворк динамической генерации синтетических задач на основе корпуса SCT [19], что исключает возможность присутствия конкретных комбинаций в обучающих данных. Chadimova и соавторы [20] показали, что замена смысловых слов в промпте хеш-значениями улучшает нормативную точность, что интерпретируется как свидетельство токен-bias. Arkoudas [21] продемонстрировал, что GPT-4 не справляется с поверхностно модифицированными версиями логических задач.

В настоящем исследовании контаминация контролируется на уровне каждого эксперимента. Для задачи Линды используется оригинальный датасет из 110 виньеток с системой демографических подстановок. Для задачи Уэйсона — четыре стимульных датасета, из которых три включают нека нонические и оригинальные стимулы. Для задачи 2-4-6 — независимый датасет из 50 правил с верификацией на отсутствие функциональных дубликатов.

1.2.3 Ограничения существующих подходов к тестированию

Анализ литературы позволяет выделить несколько системных ограничений, характерных для существующих исследований когнитивных предубеждений в LLM.

Узость охвата моделей. Большинство работ тестируют одну-две модели, как правило из семейства GPT [3; 4], что не позволяет делать выводы о том, являются ли наблюдаемые паттерны специфическими для конкретной архитектуры или универсальными.

Бинарность метрик. Преобладающим подходом является подсчёт доли правильных/ошибочных ответов [5; 18]. Эта метрика не различает модель, дающую правильный ответ с уверенностью 51%, и модель, дающую его с уверенностью 99%. Между тем уверенность модели в ошибочном ответе является самостоятельной характеристикой силы предубеждения.

Изоляция парадигм. Каждая работа, как правило, фокусируется на одной задаче и не рассматривает предубеждения как феномен, существующий на спектре [22]. Это не позволяет исследовать, связаны ли предубеждения в разных парадигмах на уровне отдельных моделей.

Отсутствие анализа стабильности. Большинство работ сообщают результаты по одной версии промпта и одному порядку предъявления стимулов, не измеряя вариабельность ответов модели как самостоятельную переменную [5].

Настоящее исследование адресует каждое из перечисленных ограничений: тестируются девять моделей, вводится непрерывная метрика силы предубеждения, исследуются три парадигмы в едином дизайне, а стабильность ответов измеряется через систематическую перестановку стимулов.

1.3 Обзор смежных исследований

1.3.1 Ошибка конъюнкции и эвристика репрезентативности в LLM

Задача Линды была одной из первых классических психологических парадигм, применённых к тестированию языковых моделей. Binz и Schulz [3] включили её в свой систематический бенчмарк GPT-3 и обнаружили, что модель воспроизводит ошибку конъюнкции в условиях, аналогичных человеческому эксперименту. Авторы

интерпретировали этот результат как свидетельство того, что GPT-3 использует эвристику репрезентативности. Suri и соавторы [4] расширили эту линию исследований на GPT-3.5 и показали, что модель демонстрирует ошибку конъюнкции с частотой, сопоставимой с человеческой (≈80%), что указывает на воспроизведение нормативно некорректного паттерна. Wang и соавторы [23] сосредоточились на манипуляции репрезентативностью: они показали, что современные модели (GPT-4, Claude) реже допускают ошибку конъюнкции, чем более ранние, однако сохраняют чувствительность к нарративной согласованности конъюнктивного элемента.

Jiang и соавторы [18] ввели понятие *токен-bias*: предрасположенности модели выбирать ответ с более высокой априорной вероятностью в языковом корпусе вне зависимости от логической структуры задачи. Для его измерения авторы использовали тест МакНемара на парах задач с коррелированным и некоррелированным конъюнктивным элементом — подход, непосредственно воспринятый в настоящем исследовании.

Ryu и соавторы [24] и Saeedi и Goodarzi [25] подтвердили устойчивость ошибки конъюнкции в различных моделях и формулировках, в том числе при смене языка промпта. Chadimova и соавторы [20] предложили интерпретацию через механизм токен-предубеждения: замена нарративно нагруженных слов на нейтральные хеш-значения существенно снижает частоту ошибки.

1.3.2 Задача выбора карточек Уэйсона в LLM

Задача Уэйсона является наиболее изученной логической парадигмой в исследованиях LLM. Binz и Schulz [3] показали, что GPT-3 решает каноническую абстрактную версию правильно, однако это, по всей видимости, является следствием memorization: при перестановке карточек точность падает. Arkoudas [21] продемонстрировал, что GPT-4 не справляется со структурно эквивалентной задачей при поверхностной модификации стимулов.

Dasgupta и соавторы [17] провели наиболее методологически строгое исследование: они использовали специально сконструированные деконтаминированные стимулы и обнаружили, что крупные модели воспроизводят контент-эффекты, аналогичные человеческим — социальные контракты решаются точнее, чем абстрактные правила, что согласуется с теорией прагматических схем рассуждения [26].

Macmillan-Scott и Musolesi [5] провели масштабный бенчмарк нескольких моделей и выявили существенную вариабельность: одни модели демонстрируют точность, близкую к потолку, другие — систематические ошибки предубеждения соответствия (matching bias). Авторы также зафиксировали высокую нестабильность ответов при повторных запросах с идентичными промптами, что поставило вопрос о надёжности точечных оценок.

Seals и Shalin [27] исследовали дедуктивную компетентность LLM в расширенном наборе логических задач и пришли к выводу, что современные модели демонстрируют систематическую зависимость от поверхностных признаков стимула, а не от логической структуры. Это согласуется с предубеждением соответствия, описанным Эвансом [28].

1.3.3 Индуктивное открытие правил и задача 2-4-6 в LLM

Исследования индуктивного рассуждения LLM значительно менее развиты по сравнению с вероятностными и логическими задачами. Banatt и соавторы [11] разработали бенчмарк WILT — первый систематический инструмент оценки LLM в многоходовой задаче открытия правил. Их результаты показывают, что более крупные модели демонстрируют более высокий успех в открытии правил, однако все модели проявляют признаки предубеждения подтверждения: доля подтверждающих тестов превышает нормативную.

Bazigaran и Sohn [29] исследовали концептуальное обобщение в LLM на материале «числовой игры» Тененбаума [15] и обнаружили паттерны, частично соответствующие байесовскому обновлению убеждений. Coda-Forno и соавторы [30] включили задачи индуктивного рассуждения в комплексный когнитивный бенчмарк CogBench и пришли к выводу, что текущие LLM демонстрируют существенный разрыв с нормативной моделью именно в задачах, требующих активного поиска фальсифицирующих свидетельств.

Batista и Griffiths [31] предложили теоретическое объяснение: склонность LLM к подтверждающим тестам может быть рационально обоснована в контексте сикофантических паттернов, усиленных обучением с подкреплением на основе обратной связи от человека. Согласно этой гипотезе, модели, оптимизированные

на одобрение человека, могут воспроизводить предпочтение подтверждающей информации как следствие смещения функции вознаграждения.

1.3.4 Сравнительные бенчмарки когнитивных предубеждений в LLM

Ряд работ ставил задачу систематического сравнения нескольких когнитивных задач на одном и том же наборе моделей. Koo и соавторы [32] разработали бенчмарк когнитивных предубеждений для LLM в роли оценщиков, охватывающий несколько типов bias, и обнаружили, что инструктируемые модели воспроизводят человекоподобные предубеждения при оценке качества текстов.

Macmillan-Scott и Musolesi [5] и Yax и соавторы [22] продемонстрировали, что профиль предубеждений существенно варьируется между моделями и не определяется однозначно размером или семейством. Coda-Forno и соавторы [30] создали наиболее полный на момент публикации сравнительный фреймворк, охватывающий задачи из области вероятностного рассуждения, обучения с подкреплением и межвременного выбора.

Настоящее исследование развивает эту линию, фокусируясь на трёх парадигмах, образующих концептуально связный спектр от вероятностного суждения до индуктивного открытия правил, и расширяя охват до девяти моделей с введением оригинальных непрерывных метрик.

1.4 Образ решения: исследовательские гипотезы

1.4.1 Гипотеза об универсальности предубеждений

На основании анализа литературы формулируется первая исследовательская гипотеза.

Гипотеза H1 (универсальность). *Все тестируемые языковые модели демонстрируют статистически значимое предубеждение подтверждения во всех трёх парадигмах относительно нормативного стандарта.*

Основанием для данной гипотезы служат следующие соображения. Обучающие корпуса всех современных LLM преимущественно состоят из текстов, порождённых людьми, в которых человекоподобные паттерны рассуждения, включая систематические ошибки, представлены значительно шире, чем нормативно корректные рассуждения. Кроме того, процедура RLHF (обучения с подкреплением на основе обратной связи от человека) дополнительно усиливает воспроизведение паттернов, одобряемых людьми-оценщиками, которые сами подвержены предубеждениям [31]. Наконец, эмпирические данные предшествующих работ [3; 5; 11] согласуются с наличием предубеждений у всех протестированных моделей, пусть и с различной интенсивностью.

1.4.2 Гипотеза о масштабировании и снижении предубеждений

Гипотеза H2 (масштабирование). *Более крупные модели демонстрируют более низкий уровень когнитивных предубеждений, однако данная зависимость не является монотонной и может нарушаться внутри модельных семейств.*

Связь между размером модели и когнитивными способностями документирована в ряде работ [11; 17]. Однако механизм этой зависимости остаётся дискуссионным: снижение предубеждений при увеличении размера может объясняться как улучшением базовых навыков рассуждения, так и более полным memorization нормативных ответов на классические задачи. Вторая часть гипотезы — о возможном нарушении монотонности — мотивирована предварительным анализом данных, выявившим паттерн, при котором меньшие модели одного семейства демонстрируют более низкий уровень предубеждений, чем большие.

1.4.3 Гипотеза о спектральной природе предубеждений

Гипотеза H3 (спектральность). *Интенсивность когнитивных предубеждений систематически возрастает от вероятностной парадигмы к логической и далее к индуктивной, отражая возрастающую сложность требуемого рассуждения.*

Данная гипотеза основана на предположении о том, что более сложные типы рассуждения (многоходовое индуктивное обновление убеждений) в большей мере опираются на эвристические стратегии, чем более простые (одношаговое вероятностное суждение). Следствием является ожидание, что все модели будут

демонстрировать наиболее высокий уровень ошибок в задаче 2-4-6 и наиболее низкий — в задаче Линды (при контроле за базовым уровнем сложности задач).

1.4.4 Гипотеза о демографическом токен-bias

Гипотеза H4 (демографический bias). *Демографические переменные, кодируемые именем персонажа, оказывают статистически значимое влияние на интенсивность ошибки конъюнкции, при этом различия будут более выражены по оси расы, чем по осям возраста и пола.*

Гипотеза мотивирована методологическими соображениями: если токен-bias действительно определяется ассоциативными связями в обучающем корпусе, то демографические токены, имеющие различную частотность и различные ассоциативные профили, должны порождать различные уровни bias. Дизайн с фиксированными шаблонами и операцией строковой замены [18] позволяет изолировать эффект демографических токенов от возможных конфаундеров нарративного стиля.

1.5 Требования к экспериментальному исследованию

1.5.1 Требования к датасетам и контролю контаминации

На основании анализа ограничений существующих подходов формулируются следующие требования к датасетам.

Оригинальность стимулов. Все биографические виньетки для задачи Линды должны быть составлены вручную и не воспроизводить текст оригинальной задачи или её известных адаптаций. Для задачи Уэйсона и задачи 2-4-6 стимулы должны включать деконтаминированные условия с оригинальным содержанием.

Структурное единообразие. Все виньетки и правила одного условия должны быть сконструированы по единому шаблону, исключающему конфаундеры, связанные с различиями в нарративном стиле или синтаксической сложности.

Размер и балансированность. Датасеты должны обеспечивать достаточную статистическую мощность для применения используемых тестов. Для теста МакНемара необходимо минимум 25–30 дискордантных пар на каждое сравниваемое условие; для оценки демографических эффектов — достаточное число подстановок на каждую расовую группу.

Верификация. Каждый элемент датасета должен пройти проверку на отсутствие функциональных дубликатов, тематических пересечений с известными источниками и логических противоречий.

1.5.2 Требования к метрикам и статистическому выводу

Совместное использование бинарных и непрерывных метрик. Наряду с долей правильных/ошибочных ответов должна применяться непрерывная метрика, учитывающая уверенность модели в своём выборе. Это обеспечивает обнаружение предубеждений в режиме «потолка точности», когда бинарная метрика не различает модели.

Парный дизайн и тест МакНемара. Для сравнения условий (correlated vs. uncorrelated; с перестановкой vs. без) должен применяться тест МакНемара, использующий парную структуру данных и обладающий более высокой статистической мощностью, чем независимые тесты [9].

Контроль множественных сравнений. При сравнении нескольких демографических групп или условий промпта должна применяться процедура коррекции на множественные сравнения [10].

Воспроизводимость. Все модели должны запрашиваться с фиксированными параметрами (temperature = 0 для детерминированных условий), а сырые ответы сохраняться отдельно от производных метрик.

1.5.3 Требования к набору тестируемых моделей

Для обеспечения широкой генерализуемости выводов набор тестируемых моделей должен удовлетворять следующим критериям.

Разнообразие провайдеров и архитектур. Набор должен включать модели от не менее чем четырёх различных провайдеров, охватывая как проприетарные (OpenAI, Anthropic, xAI), так и открытые (Google, Alibaba, Zhipu) системы.

Разнообразие размеров. Набор должен включать модели как уровня «малые» (7–12B параметров), так и «крупные» (70B+ параметров), что позволяет проверить гипотезу о масштабировании.

Единообразие условий доступа. Все модели должны запрашиваться через единый API-интерфейс для исключения артефактов, связанных с различием в препроцессинге промптов или постпроцессинге ответов.

2 ДИЗАЙН И ПРОВЕДЕНИЕ ЭКСПЕРИМЕНТОВ

2.1 Обзор экспериментального фреймворка

2.1.1 Три парадигмы как единый спектр

Настоящее исследование объединяет три классические психологические парадигмы в едином экспериментальном фреймворке, обеспечивающем сопоставимость результатов на уровне моделей, метрик и условий доступа. Выбор парадигм обусловлен концептуальной логикой: они образуют прогрессирующий спектр сложности рассуждения и типа когнитивного предубеждения.

Эксперимент 1 (ошибка конъюнкции) тестирует вероятностное суждение в одношаговом формате: модели предъявляется описание персонажа и два варианта ответа, один из которых нормативно правильный. Ошибка возникает в момент выбора и не требует многошагового вывода.

Эксперимент 2 (задача выбора карточек Уэйсона) тестирует дедуктивное рассуждение: модель должна применить правило modus tollens к условному утверждению и выбрать карточки, способные его фальсифицировать. Задача является одношаговой, однако требует явного логического анализа структуры правила.

Эксперимент 3 (задача открытия правила 2-4-6) тестирует индуктивное рассуждение в многоходовом интерактивном формате: модель должна итеративно формировать и пересматривать гипотезы на основе бинарной обратной связи. Предубеждение проявляется не в единственном выборе, а в стратегии тестирования на протяжении всего диалога.

Все три эксперимента проводились на одном и том же наборе из девяти моделей, что позволяет сравнивать профили предубеждений между парадигмами на уровне отдельных систем.

2.1.2 Общие принципы дизайна

Три принципа обеспечивают методологическую связность фреймворка.

Контроль контаминации. В каждом эксперименте используются оригинальные датасеты, не воспроизводящие текст классических задач или их известных адаптаций. Детали контроля контаминации описаны в соответствующих подразделах.

Воспроизводимость. Все модели запрашивались через единый API-интерфейс (OpenRouter). Сырые ответы сохранялись отдельно от производных метрик. Случаи нарушения формата фиксировались и обрабатывались через retry-логику.

Сопоставимость метрик. Наряду со специфическими для каждого эксперимента показателями вводится единая метрика Severity of Bias, обеспечивающая сквозное сравнение интенсивности предубеждений между парадигмами.

2.2 Эксперимент 1: Ошибка конъюнкции (Задача Линды)

2.2.1 Обоснование выбора парадигмы

В качестве экспериментальной парадигмы для исследования вероятностных предубеждений была выбрана задача ошибки конъюнкции, впервые описанная Тверски и Канеманом [6]. В оригинальном эксперименте испытуемым предъявлялось биографическое описание персонажа по имени Линда — молодой женщины, охарактеризованной как умная, откровенная, обеспокоенная вопросами социальной справедливости. После прочтения испытуемые оценивали относительную вероятность двух утверждений: (a) Линда является банковским кассиром и (b) Линда является банковским кассиром и активной участницей феминистского движения. Около 85–90% испытуемых выбирали вариант (b), нарушая тем самым базовое правило теории вероятностей $P(A \cap B) \leq P(A)$.

Задача была выбрана по трём причинам. Во-первых, она обладает чётко определённым нормативным ответом,

что позволяет однозначно классифицировать ответы модели. Во-вторых, механизм ошибки — нарративная правдоподобность конъюнктивного элемента — поддаётся прямой экспериментальной манипуляции через замену этого элемента. В-третьих, задача широко использовалась в предшествующих исследованиях [3–5; 18; 23], что обеспечивает возможность сравнения результатов.

2.2.2 Проблема контаминации и подходы к её решению

Задача Линды является одной из наиболее цитируемых задач в психологической литературе и с высокой вероятностью присутствует в обучающих данных большинства современных LLM [16]. Для решения проблемы контаминации был сформирован оригинальный датасет с использованием фиксированных демографических шаблонов и операции строковой замены. Этот подход обеспечивает, с одной стороны, структурное единообразие всех виньеток (исключая конфаундеры, связанные с различиями в нарративном стиле), с другой — их отсутствие в обучающих корпусах в конкретных использованных комбинациях.

2.2.3 Конструкция датасета: биографические виньетки

Датасет состоит из 110 оригинальных биографических виньеток, составленных вручную. Каждая виньета описывает персонажа с выраженными личностными характеристиками, создающими сильный нарративный образ, и содержит плейсхолдеры `{NAME}`, `{RACE}` и `{AGE}`, заменяемые в ходе подстановки. Пример виньетки:

> *"{NAME} is a {RACE} {AGE}-year-old public defender who takes on cases others refuse. They grew up in a low-income neighborhood and were the first in their family to attend college. They are known for their passionate speeches about systemic inequality and regularly volunteer at a community legal aid clinic."*

К каждой виньете прилагаются пять элементов:

- **T** — простая опция, содержащая профессию персонажа. Профессии сэмплировались из базы статистики занятости USDL/OEWS [33], насчитывающей около 830 профессиональных категорий;
- **F** — коррелированное хобби, тематически релевантное биографии, но не воспроизводящее дословно ни одного слова из виньетки;
- **F_uncorrelated** — некоррелированное хобби, семантически не связанное с биографией персонажа;
- **T_and_F1** — конъюнктивная опция T + F;
- **T_and_F2** — конъюнктивная опция T + F_uncorrelated.

Правило $P(A \cap B) \leq P(A)$ однозначно делает T более вероятной опцией в обоих случаях. Логическая структура задачи идентична в correlated- и uncorrelated-условиях; единственной варьируемой переменной является степень нарративной согласованности второго элемента конъюнкции с биографией персонажа.

2.2.4 Демографические подстановки и факториальный дизайн

Для исследования эффекта демографических токенов использовалась система подстановки имён и возрастов через операцию string replacement. Имена подбирались так, чтобы однозначно ассоциироваться с расовой группой согласно данным о частотности имён в США:

- **White:** Emma, James
- **Black:** Jamal, Aisha
- **Hispanic:** Carlos, Maria
- **Asian:** Wei, Priya

Возрасты: 24, 38, 55 лет. Первоначально эксперимент проводился на полной факториальной сетке: 8 имён $\times$ 3 возраста = 24 варианта подстановки на виньетку, что давало более 6000 пар испытаний для первых моделей. Однако анализ результатов не выявил значимых различий по возрасту и proxy-gender: delta_bias по возрастным группам варьировался в диапазоне $-0{,}005 \div +0{,}003$, групповые тесты МакНемара не прошли порог значимости после коррекции Бенджамини-Хохберга [10]. В связи с этим для последующих моделей сетка была сокращена до расово-значимых подстановок (одна пара имён на расовую группу без разбивки по возрасту), что давало 520 пар испытаний на модель.

2.2.5 Протокол эксперимента и промпт-структура

Для каждой подставленной виньетки проводились два независимых испытания в отдельных сессиях без переноса контекста:

Условие A (correlated): модели предъявлялись опции T и T_and_F1. Правильный ответ — выбор T.

Условие B (uncorrelated): модели предъявлялись опции T и T_and_F2. Правильный ответ — выбор T.

Промпт имел следующую структуру:

> *Read the following description and answer the question.*
> *[vignette]*
> *Which is more probable?*
> *(a) [T]*
> *(b) [T_and_F1 or T_and_F2]*
> *First state your choice: only the letter (a) or (b).*
> *Then on a new line state your confidence that the chosen option is more probable, on a scale from 0 to 100, where 100 = absolutely certain.*

Все модели запрашивались с параметром temperature = 0. Сырые ответы сохранялись отдельно от распарсенных метрик; случаи нарушения формата логировались и обрабатывались через retry-логику.

2.2.6 Метрики: бинарная точность, тест МакНемара, Severity of Bias

Бинарная метрика и тест МакНемара. Основным инструментом статистического вывода служил точный тест МакНемара для согласованных пар бинарных наблюдений [9]. Для каждой пары испытаний (A, B) одной подставленной виньетки строилась таблица 2×2 с ячейками n_{11} (правильно в обоих условиях), n_{12} (правильно в A, ошибочно в B), n_{21} (ошибочно в A, правильно в B), n_{22} (ошибочно в обоих условиях). Нулевая гипотеза предполагает маргинальную однородность: $\pi_{12} = \pi_{21}$. Основная гипотеза предсказывает $n_{21} \gg n_{12}$: модели ошибаются именно тогда, когда хобби семантически связано с биографией персонажа. При $n^* = n_{12}+n_{21} > 10$ использовалась нормальная аппроксимация со статистикой $z_0 = (n_{21} - n_{12})/\sqrt{n_{21} + n_{12}}$.

Severity of Bias. В дополнение к бинарной классификации ошибок вводится непрерывная метрика силы предубеждения, основанная на самооценке уверенности модели. Для каждого испытания:

– если модель выбирала конъюнкцию (b): bias_score $=$ confidence$/100$;
– если модель выбирала T (a): bias_score $= (100 -$ confidence$)/100$.

Шкала от 0 (минимальное предубеждение, высокая уверенность в правильном ответе) до 1 (максимальное предубеждение, высокая уверенность в ошибочном ответе). Ключевой агрегированной метрикой является:

$$\text{delta_bias} = \overline{\text{bias}}_{\text{correlated}} - \overline{\text{bias}}_{\text{uncorrelated}}, \tag{2.1}$$

где $\overline{\text{bias}}_{\text{correlated}}$ и $\overline{\text{bias}}_{\text{uncorrelated}}$ — средние значения bias_score в соответствующих условиях. Это значение отражает чистый эффект нарративной связности, очищенный от фонового уровня неуверенности модели. Статистическая значимость delta_bias проверялась парным t-тестом и критерием Вилкоксона.

2.2.7 Результаты и анализ

Полные результаты эксперимента по всем девяти моделям представлены в таблице 2.1.

Примечание: n_{21} — число пар, в которых ошибка совершена только в correlated-условии; знак «+*» для `claude-sonnet-4.6` означает значимый delta_bias при бинарно незначимом тесте МакНемара. В столбце McNemar p для `qwen3.5-397b-a17b` указано $p = 0{,}0625$, что не проходит порог $\alpha = 0{,}05$.

Гипотеза H1 об универсальности токен-bias получила *частичное* подтверждение. Из девяти моделей у восьми выполняется $n_{21} > n_{12} = 0$ и delta_bias > 0, что свидетельствует о систематической склонности ошибаться именно в correlated-условии. Однако для двух моделей результат требует оговорок.

claude-sonnet-4.6 демонстрирует феномен «потолка бинарной точности»: за весь прогон из 520 пар допущена единственная бинарная ошибка ($n_{21} = 1$), поэтому тест МакНемара не достигает значимости ($p = 1{,}0$). Вместе с тем метрика delta_bias фиксирует устойчивый сдвиг: delta_bias $= +0{,}1049$ при $p_{\text{t-test}} = 2{,}59 \cdot 10^{-147}$,

Таблица 2.1 — Результаты эксперимента 1 по всем моделям

Модель	**n_pairs**	n_{21}	**McNemar** p	**delta_bias**	**Знак**
qwen3-next-80b	520	316	$1{,}50 \cdot 10^{-95}$	$+0{,}5648$	+
gemma-3-27b-it	520	305	$3{,}07 \cdot 10^{-92}$	$+0{,}4975$	+
gpt-5.2	520	209	$2{,}43 \cdot 10^{-63}$	$+0{,}3746$	+
grok-4.1-fast	520	119	$3{,}01 \cdot 10^{-36}$	$+0{,}2485$	+
deepseek-v3.2	520	97	$1{,}26 \cdot 10^{-29}$	$+0{,}1996$	+
gemma-3-12b-it	520	14	$0{,}000122$	$+0{,}0370$	+
glm-4.7-flash	3120	26	$2{,}98 \cdot 10^{-8}$	$+0{,}0279$	+
claude-sonnet-4.6	520	1	$1{,}0$	$+0{,}1049$	+*
qwen3.5-397b-a17b	3120	5	$0{,}0625$	$-0{,}0052$	-

$p_{\text{Wilcoxon}} = 9{,}60 \cdot 10^{-83}$. Модель систематически демонстрирует сниженную уверенность в правильном ответе именно в correlated-условии, не совершая при этом классификационных ошибок. Это подтверждает, что токен-предубеждение существует на спектре и не сводится к дихотомии «ошибается / не ошибается».

qwen3.5-397b-a17b является единственной моделью, для которой не обнаружено свидетельств токен-bias: $n_{21} = 5$, $n_{12} = 0$, $p_{\text{McNemar}} = 0{,}0625$, delta_bias $= -0{,}0052$ (отрицательный знак). Статистически значимые p-значения t-теста и критерия Вилкоксона ($p = 5{,}27 \cdot 10^{-10}$ и $p = 6{,}27 \cdot 10^{-44}$ соответственно) объясняются не направленным bias, а микросдвигом в калибровке уверенности при практически нулевой вариативности ошибок: модель почти всегда отвечает правильно с высокой уверенностью, и статистически значимое различие между условиями отражает лишь тонкую разницу в распределениях confidence, а не выраженный токен-bias.

Внутрисемейный парадокс масштаба является одним из наиболее неожиданных результатов эксперимента. Внутри семейства Gemma более крупная модель проявляет несравнимо более высокий уровень предубеждения: у `gemma-3-27b-it` $n_{21} = 305$ и delta_bias $= 0{,}4975$ против $n_{21} = 14$ и delta_bias $= 0{,}0370$ у `gemma-3-12b-it`. Это прямо противоречит гипотезе H2 о монотонном снижении предубеждений с ростом размера модели. Наиболее правдоподобное объяснение: более крупная модель лучше распознаёт нарративную согласованность биографии и конъюнктивного элемента, что парадоксально усиливает эвристику репрезентативности. Меньшая модель, хуже улавливая «смысл» биографии, реже попадает в эту ловушку.

Демографический анализ. По модели `glm-4.7-flash` зафиксирован расовый эффект: delta_bias для Asian (0,0318), Hispanic (0,0314) и Black (0,0248) значимо выше нуля после коррекции BH-FDR, тогда как для White отдельный тест МакНемара незначим. По остальным моделям — `qwen3.5-397b-a17b`, `gemma-3-12b-it` — расовых различий не выявлено. Возраст и proxy-gender (кодировка через имя) не дали значимых эффектов ни у одной модели, что согласуется с решением сократить факториальную сетку для последующих моделей.

2.2.8 Выводы по эксперименту 1

Эксперимент 1 установил: (1) токен-bias в форме ошибки конъюнкции выявлен у восьми из девяти моделей, что даёт основания говорить о широко распространённом, но не абсолютно универсальном феномене; (2) метрика Severity of Bias обнаруживает предубеждение там, где бинарная метрика показывает потолок точности, что подтверждено на примере `claude-sonnet-4.6`; (3) эффект масштабирования не является монотонным: внутри семейства Gemma более крупная модель демонстрирует многократно более высокий уровень предубеждения; (4) расовый демографический эффект зафиксирован у `glm-4.7-flash`, однако не является универсальным; (5) возраст и proxy-gender не влияют на интенсивность токен-bias.

2.3 Эксперимент 2: Задача выбора карточек Уэйсона

2.3.1 Обоснование выбора парадигмы

Задача выбора карточек Уэйсона [7] была выбрана как каноническая парадигма для исследования предубеждения подтверждения в дедуктивном рассуждении. В оригинальной версии испытуемым предъявляются четыре карточки, соответствующие случаям P, ¬P, Q и ¬Q, и условное правило «если P, то Q». Нормативно правильный ответ — выбор карточек P и ¬Q — позволяет фальсифицировать правило. Менее

10% людей решают абстрактную версию правильно; большинство выбирают подтверждающие карточки P и Q.

Задача обеспечивает прямую операционализацию предубеждения подтверждения [14]: выбор карточек P и Q отражает поиск подтверждающих, а не фальсифицирующих свидетельств. Кроме того, задача позволяет исследовать контент-эффекты [26; 34]: известно, что задачи с содержанием социальных контрактов решаются людьми значительно лучше, чем абстрактные версии.

2.3.2 Конструкция стимульных датасетов: четыре контентных условия

Были сконструированы четыре стимульных датасета, каждый включающий 100 уникальных условных правил с соответствующими отображениями на четыре позиции карточек.

Формальная логика — Каноническая. Правила используют стандартные абстрактные символы из классической литературы по задаче Уэйсона (буквы, числа, геометрические фигуры). Условие включено для сравнения с предшествующими работами при признании риска контаминации [3; 21].

Формальная логика — Нейтральная. Правила используют оригинальные абстрактные пары, не присутствующие в канонических формулировках (например, «если символ является Стрелкой, то узор является Полосатым»). Это условие служит деконтаминированным абстрактным базисом и непосредственно адресует методологический пробел работ, опирающихся исключительно на канонические стимулы.

Конкретные факты. Правила основаны на верифицируемых реальных свойствах объектов (например, «если животное является дельфином, то оно дышит воздухом»). Условие операционализирует семантические априорные знания без введения нормативных социальных обязательств.

Знакомые социальные контракты. Деонтические правила, отражающие широко известные социальные нормы и институциональные разрешения (например, «если человек управляет автомобилем, то у него должны быть права»). Условие воспроизводит эффект фасилитации, описанный Ченгом и Холиоаком [26]. Из набора исключены юрисдикционно-специфические правила.

Незнакомые фантастические социальные контракты. Деонтические правила, вписанные в вымышленные миры, не пересекающиеся с известными художественными вселенными (например, «если путешественник пересекает Лунные ворота, он должен нести Серебряное перо»). Условие разработано для диссоциации двух конкурирующих объяснений эффекта социального контракта: знакомость конкретного содержания правила или распознавание деонтической структуры разрешения/обязательства [26; 34]. Насколько известно автору, подобное условие ранее не реализовывалось в исследованиях LLM.

2.3.3 Протокол перестановок порядка карточек

Ключевым методологическим вкладом дизайна является систематическая манипуляция порядком предъявления карточек. Каждый стимул предъявлялся каждой модели в **пяти различных перестановках** четырёх позиций карточек. Это следует из наблюдения Binz и Schulz [3] о том, что единственное изменение перестановки способно обратить ответ GPT-3 на каноническую задачу, и из данных Macmillan-Scott и Musolesi [5] о существенной нестабильности ответов LLM.

Данный дизайн даёт **500 испытаний на модель на условие** (100 правил $\times$ 5 перестановок), позволяя оценивать распределения ответов, а не точечные оценки, и разделять правильность и стабильность как независимые свойства поведения модели.

2.3.4 Промпт-условия

Оценивались два промпт-условия на датасете «Формальная логика — Нейтральная» и дополнительно на «Знакомых социальных контрактах».

Neutral. Предъявляет задачу без стратегических указаний, без персоны эксперта и без фрейминга фальсификации. Наиболее близко воспроизводит оригинальную человеческую экспериментальную парадигму и служит основным измерением непромпт-ированной логической компетентности.

Chain-of-Thought (CoT). Инструктирует модель рассуждать пошагово перед ответом [13]:

You are a logic expert analyzing conditional rules. Think step by step before answering. After reasoning,

output your final answer on the last line as: ANSWER: card1, card2.

Условие CoT тестирует, раскрывает ли явное элицирование рассуждений латентную компетентность у моделей, недостаточно показывающих себя при прямых ответах, и взаимодействует ли CoT дифференцированно с уровнем способностей модели [35].

Все модели запрашивались с temperature = 1,0 для сохранения естественной вариабельности ответов между перестановками. Примеры не предоставлялись; все условия — zero-shot.

2.3.5 Метрики

Expected Metric Accuracy (EMA) — доля испытаний, в которых модель выбирает ровно нормативно правильный набор карточек {P, ¬Q}. Основная мера логической правильности, сопоставимая с метриками точности в работах Dasgupta и соавторов [17] и Macmillan-Scott и Musolesi [5].

Matching Bias Index (MBI) — доля испытаний, в которых модель выбирает {P, Q} — карточки, явно упомянутые в правиле [28]. Операционализирует предубеждение соответствия.

Confirmation Bias Rate (CBR) — доля испытаний, в которых модель выбирает только {P} — минимальный подтверждающий выбор. Совместно с MBI формирует «семейство предубеждения подтверждения».

Consistency Rate — доля правил, для которых модель даёт идентичный выбор карточек во всех пяти перестановках. Количественно оценивает стабильность ответов независимо от правильности.

2.3.6 Результаты и анализ

Результаты по контентным условиям. Полные данные по всем пяти датасетам приведены в таблицах 2.2 и 2.3.

Таблица 2.2 — EMA по контентным условиям (Formal Logic Canonical и Neutral)

Модель	FL Canon.	FL Neutral	Conc. Facts	Fam. Social
gpt-5.2	0,962	0,972	0,976	0,996
qwen3-next-80b	0,834	0,976	0,980	0,946
qwen3.5-397b-a17b	0,822	0,818	0,909	0,982
claude-sonnet-4.6	0,814	0,898	0,956	0,982
deepseek-v3.2	0,764	0,880	0,883	0,922
grok-4.1-fast	0,634	0,720	0,875	0,818
gemma-3-27b-it	0,716	0,578	0,792	0,904
glm-4.7-flash	0,464	0,614	0,562	0,686
gemma-3-12b-it	0,332	0,106	0,380	0,546

Таблица 2.3 — EMA и Consistency Rate в условии Unfamiliar Fantasy Social Contracts

Модель	Fantasy Social EMA	Confirmation-fam.	Consistency
qwen3.5-397b-a17b	0,986	0,004	0,950
gpt-5.2	0,978	0,010	0,920
claude-sonnet-4.6	0,970	0,024	0,920
qwen3-next-80b	0,938	0,030	0,780
gemma-3-27b-it	0,888	0,104	0,750
deepseek-v3.2	0,882	0,028	0,580
grok-4.1-fast	0,818	0,082	0,440
glm-4.7-flash	0,590	0,334	0,260
gemma-3-12b-it	0,436	0,240	0,170

Контент-эффект является наиболее устойчивым результатом эксперимента и воспроизводится у всех девяти моделей. Переход от абстрактного нейтрального условия к знакомым социальным контрактам даёт прирост EMA во всех без исключения случаях: медианный прирост составляет $+0{,}31$ (от $+0{,}164$ у `qwen3.5-397b-a17b` до $+0{,}440$ у `gemma-3-12b-it`). Критически важным является результат условия «Незнакомых фантастических социальных контрактов»: EMA в нём значимо превышает EMA в нейтральном абстрактном условии у восьми из девяти моделей и вплотную приближается к EMA знакомых социальных контрактов. Это

поддерживает гипотезу прагматических схем [26]: деонтическая структура обязательства фасилитирует правильный логический вывод независимо от знакомости содержания.

Исключением является `gemma-3-27b-it`, у которой EMA в условии Fantasy (0,888) превышает EMA в Familiar (0,904) незначительно, но при этом EMA в нейтральном абстрактном условии (0,578) заметно ниже — что указывает на особую чувствительность этой модели именно к деонтическому фреймингу.

Предубеждение подтверждения подтверждено для всех моделей в нейтральном промпт-условии (таблица 2.4). В Formal Logic Neutral при нейтральном промпте `gemma-3-12b-it` демонстрирует Confirmation-family = 0,670 (MBI = 0,536 + CBR = 0,134) при EMA = 0,106 — модель в 6,4 раза чаще выбирает предубеждённый ответ, чем правильный.

Таблица 2.4 — Сравнение промпт-условий на датасете Formal Logic Neutral

Модель	**Neutral prompt**			**CoT prompt**		
	EMA	MBI	CBR	EMA	MBI	CBR
gpt-5.2	0,884	0,056	0,002	0,976	0,006	0,006
claude-sonnet-4.6	0,790	0,172	0,002	0,970	0,000	0,000
qwen3-next-80b	0,772	0,038	0,024	0,880	0,000	0,004
qwen3.5-397b-a17b	0,764	0,032	0,000	0,974	0,000	0,004
deepseek-v3.2	0,658	0,200	0,002	0,936	0,000	0,002
grok-4.1-fast	0,424	0,450	0,000	0,664	0,032	0,252
gemma-3-27b-it	0,406	0,386	0,006	0,368	0,436	0,120
glm-4.7-flash	0,332	0,304	0,248	0,258	0,086	0,548
gemma-3-12b-it	0,028	0,270	0,134	0,186	0,468	0,230

Эффект CoT-промпта является одним из наиболее содержательных результатов. Для топ-5 моделей CoT даёт существенный прирост EMA: `claude-sonnet-4.6` (+0,180), `qwen3.5-397b-a17b` (+0,210), `deepseek-v3.2` (+0,278), при этом MBI и CBR у всех пяти моделей падают практически до нуля. Однако для нижней части рейтинга CoT не только не помогает, но и вредит. У `glm-4.7-flash` EMA снижается с 0,332 до 0,258, а CBR вырастает с 0,248 до 0,548: явное рассуждение систематически приводит эту модель к выбору только карточки {P}. У `gemma-3-27b-it` CoT не меняет EMA содержательно (0,406 vs 0,368), однако перераспределяет ошибки: MBI растёт с 0,386 до 0,436, то есть явное рассуждение усиливает предубеждение соответствия. Это указывает на то, что CoT не является универсальным средством коррекции предубеждений и может давать обратный эффект у моделей с недостаточной базовой логической компетентностью [35].

Стабильность ответов в Formal Logic Neutral при нейтральном промпте: от 0,110 у `gemma-3-12b-it` до 0,910 у `qwen3-next-80b`. Примечательно, что `qwen3-next-80b` демонстрирует наивысшую стабильность (0,910) при EMA 0,976 — сочетание, нетипичное для других моделей. `gemma-3-27b-it` при EMA 0,578 имеет стабильность 0,280 — низкую относительно точности, что указывает на нестабильное угадывание, а не на систематическое рассуждение.

Внутрисемейный парадокс. В семействе Gemma эффект из эксперимента 1 инвертируется: по EMA в Formal Logic Neutral `gemma-3-27b-it` (0,578) значительно превосходит `gemma-3-12b-it` (0,106). Таким образом, в вероятностной задаче 27b была более уязвима, чем 12b, а в логической задаче — менее уязвима. Это указывает на то, что уязвимость к разным типам когнитивных предубеждений не определяется единым фактором и может иметь различную направленность в зависимости от типа рассуждения.

2.3.7 Выводы по эксперименту 2

Эксперимент 2 установил: (1) предубеждение подтверждения в дедуктивном рассуждении у всех девяти моделей в нейтральном условии; (2) устойчивый контент-эффект — социальные контракты решаются значимо лучше абстрактных правил у всех моделей; (3) поддержку гипотезы прагматических схем Ченга-Холиоака через условие фантастических социальных контрактов, которое даёт EMA, сопоставимое со знакомыми контрактами; (4) дифференцированный эффект CoT — сильные модели значительно улучшают результаты, слабые ухудшают; (5) инверсию внутрисемейного парадокса Gemma по сравнению с экспериментом 1, что свидетельствует о мультидимензиональности когнитивных предубеждений.

2.4 Эксперимент 3: Задача открытия правила 2-4-6

2.4.1 Обоснование выбора парадигмы

Задача открытия правила 2-4-6, введённая Уэйсоном [8], является классической парадигмой для исследования предубеждения подтверждения в индуктивном рассуждении. В оригинальном эксперименте испытуемым сообщалось, что тройка $(2, 4, 6)$ удовлетворяет скрытому правилу, и предлагалось открыть его, предлагая новые тройки и получая бинарную обратную связь. Канонический результат: испытуемые тестируют тройки, согласующиеся с текущей гипотезой (например, $(4, 8, 10)$ для гипотезы «чётные числа в порядке возрастания»), вместо попыток фальсифицировать её, и не обнаруживают истинное правило («любая возрастающая последовательность»).

В отличие от экспериментов 1 и 2, где предубеждение проявляется в единственном ответе, здесь оно измеряется как свойство *стратегии* на протяжении многоходового диалога.

2.4.2 Конструкция датасета правил: пять таксономических категорий

Был сформирован независимый датасет из **50 правил**, организованных в пять таксономических категорий:

- **Порядок и сравнение** (9 правил) — отношения между элементами: $x < y < z$, $x > y \wedge z > y$;
- **Чётность и делимость** (10 правил) — свойства модульной арифметики: все чётные, сумма кратна 3;
- **Арифметические отношения** (10 правил) — аддитивные и мультипликативные структуры: $x + y = z$, $y - x = z - y$;
- **Структурные паттерны** (11 правил) — позиционные и теоретико-множественные свойства: $\max(x, y, z) = z$, ровно два уникальных значения;
- **Смешанные / составные** (10 правил) — конъюнкции из предыдущих категорий: $x < y < z \wedge (x+y+z) \equiv 0 \pmod 2$.

Все правила верифицированы на исполнимость в диапазоне $[1, 99]^3$, отсутствие функциональных дубликатов (проверка через экстенсиональную эквивалентность) и отсутствие тавтологий. Ряд правил намеренно сконструирован как *ловушки специфичности*: правила, являющиеся строго более специфичными, чем истинное правило, но согласующиеся с порождающей тройкой $(2, 4, 6)$. Из 50 правил **26 удовлетворяются** тройкой $(2, 4, 6)$ и 24 не удовлетворяются.

2.4.3 Многоходовой диалоговый протокол

Эксперимент реализован как многоходовой диалог. На каждом ходу t модель получает историю разговора и должна ответить в строго ограниченном формате:

```
H: lambda x, y, z: <hypothesis>
T: [x, y, z]
```

где `H` — исполняемый Python-лямбда-выражение, представляющее текущую гипотезу о скрытом правиле R, а `T` — следующая тройка для тестирования. Модель получает только бинарную обратную связь вида `(a, b, c) -> True` или `(a, b, c) -> False`. Диалог продолжается не более `max_turns` шагов. В отличие от бенчмарка WILT [11], дизайн настоящего исследования требует от модели поддерживать живую, исполняемую гипотезу *на каждом ходу*, что позволяет анализировать полную траекторию гипотез.

2.4.4 Промпт-условия: Baseline и Adaptive

Baseline. Предоставляет только фрейм задачи: существование скрытого правила, порождающую тройку, требуемый формат вывода и жёсткие ограничения (целые числа в $[1, 99]$, только `H` и `T` без пояснений).

Adaptive. Расширяет базовый промпт явными метакогнитивными указаниями, основанными на нормативном байесовском пересмотре гипотез: после получения ответа False гипотезу следует сузить; после неожиданного True — расширить; рекомендуется рассматривать арифметические свойства (суммы, произведения, остатки) как компоненты правила. Манипуляция мотивирована данными Batista и Griffiths [31] о том, что явные инструкции по обратной связи модулируют поведение пересмотра гипотез.

2.4.5 Метрики качества гипотез

Ключевой методологической особенностью является использование *экстенсиональной эквивалентности* для оценки гипотез. Вместо текстового сравнения строк гипотезы оцениваются как множества принятых троек над большой случайной выборкой [11]. Формально: для скрытого правила R и гипотезы модели H_t на ходу t сэмплируются $N = 200{,}000$ случайных троек $(x, y, z) \in [1, 99]^3$ и вычисляются булевы векторы $\mathbf{r}$ и $\mathbf{h}_t$. Метрика:

$$\mathrm{IOU}(H_t, R) = \frac{|\mathbf{h}_t \cap \mathbf{r}|}{|\mathbf{h}_t \cup \mathbf{r}|}, \tag{2.2}$$

испытание считается **успешным** при $\mathrm{IOU}(H_T, R) > 0{,}95$.

Success Rate (↑) — доля правил, для которых финальная гипотеза достигает $\mathrm{IOU} > 0{,}95$.

Mean AUC-IOU (↑) — площадь под кривой IOU по ходам, усреднённая по всем правилам:

$$\text{AUC-IOU} = \frac{1}{T} \sum_{t=1}^{T} \mathrm{IOU}(H_t, R). \tag{2.3}$$

Confirming Test Rate (CTR) (↓) — доля ходов, на которых предлагаемая тройка T_t предсказывается текущей гипотезой H_t как True:

$$\mathrm{CTR} = \frac{1}{T} \sum_{t=1}^{T} \mathbf{1}[H_t(T_t) = \text{True}]. \tag{2.4}$$

Напрямую операционализирует предубеждение подтверждения: низкий CTR соответствует фальсификационно-ориентированной стратегии.

Hypothesis Change Rate (HCR) (↑) — доля последовательных пар ходов, на которых модель существенно пересматривает гипотезу:

$$\mathrm{HCR} = \frac{1}{T-1} \sum_{t=2}^{T} \mathbf{1}[\mathrm{IOU}(H_t, H_{t-1}) < 0{,}9]. \tag{2.5}$$

Низкий HCR указывает на «залипание» в начальной гипотезе вне зависимости от полученной обратной связи.

2.4.6 Результаты и анализ

Полные результаты по baseline- и adaptive-условиям представлены в таблице 2.5.

Таблица 2.5 — Результаты эксперимента 3: baseline и adaptive условия

Модель	**SR base**	**SR adap**	**CTR base**	**CTR adap**
claude-sonnet-4.6	0,28	0,28	0,812	0,787
qwen3.5-397b-a17b	0,22	0,18	0,850	0,602
qwen3-next-80b	0,20	0,24	0,976	0,719
gpt-5.2	0,18	0,18	0,719	0,584
grok-4.1-fast	0,14	0,08	0,629	0,672
deepseek-v3.2	0,10	0,16	0,879	0,768
gemma-3-12b-it	0,06	0,04	0,747	0,718
glm-4.7-flash	0,04	0,06	0,734	0,486
gemma-3-27b-it	0,04	0,10	0,710	0,842
gpt-5.2 reasoning	0,38	0,48	0,726	0,559

Гипотеза H1 подтверждена полностью: CTR в baseline-условии варьируется от 0,629 у `grok-4.1-fast` до 0,976 у `qwen3-next-80b`. Даже наименее «подтверждающая» модель в 63% случаев тестирует тройки, которые её же текущая гипотеза предсказывает как True. Нормативная стратегия байесовского агента предполагает CTR близкий к нулю.

Success Rate низкий у всех non-reasoning моделей. Лучший результат в baseline среди них — `claude-sonnet-4.6` с $\mathrm{SR} = 0{,}28$, что означает успешное открытие правила лишь в 14 из 50 случаев. `gemma-3-27b-it` и `glm-4.7-flash` открывают правило лишь в двух случаях из 50.

Reasoning даёт качественный скачок. `gpt-5.2` в режиме reasoning (baseline) достигает $\mathrm{SR} = 0{,}38$ — на

10 процентных пунктов выше лучшей non-reasoning модели. В adaptive-условии SR вырастает до 0,48 и CTR снижается до 0,559, что является единственным случаем CTR ниже 0,60 во всём эксперименте. Таким образом, reasoning + adaptive — единственная комбинация, приближающаяся к разумной фальсификационной стратегии, хотя и не достигающая нормативного стандарта.

Adaptive-промпт нестабилен. Из девяти non-reasoning моделей у четырёх SR не изменился или снизился (`gpt-5.2`: без изменений; `qwen3.5-397b-a17b`: $0{,}22 \to 0{,}18$; `grok-4.1-fast`: $0{,}14 \to 0{,}08$; `gemma-3-12b-it`: $0{,}06 \to 0{,}04$). Снижение CTR не гарантирует роста SR.

Наиболее интригующим является **парадокс `qwen3.5-397b-a17b`**: adaptive-промпт вызвал крупнейшее снижение CTR среди non-reasoning моделей ($0{,}850 \to 0{,}602$, то есть модель стала значительно активнее фальсифицировать), однако SR упал с 0,22 до 0,18. Модель начала тестировать опровергающие тройки, но не смогла конвертировать это в правильную гипотезу — что указывает на разрыв между стратегией тестирования и качеством обновления гипотез.

Контринтуитивный эффект у `gemma-3-27b-it`: adaptive-промпт, направленный на фальсификацию, *увеличил* CTR ($0{,}710 \to 0{,}842$), однако SR при этом вырос с 0,04 до 0,10. Это указывает на то, что данная модель находит правильную гипотезу не через фальсифицирующую стратегию, а через какой-то иной механизм, нечувствительный к инструкциям по типу тестов.

AUC-IOU выявляет расхождение между качеством траектории и финальным результатом. У `gpt-5.2` reasoning при переходе baseline $\to$ adaptive: SR $+0{,}10$, но AUC-IOU $0{,}119 \to 0{,}083$ — менее гладкая траектория сходимости при лучшем финальном результате. У `deepseek-v3.2` в baseline AUC-IOU ($0{,}052$) существенно ниже, чем у `claude-sonnet-4.6` ($0{,}127$), при схожем SR, что указывает на «спринт» к правильному ответу в последних ходах без устойчивого накопления качества гипотезы.

Hypothesis Change Rate (HCR) в baseline варьируется от 0,599 у `gpt-5.2` до 0,939 у `gemma-3-27b-it`. Adaptive-промпт влияет на HCR неоднородно: у `deepseek-v3.2` HCR снижается с 0,833 до 0,535 (модель реже меняет гипотезу), у `gemma-3-27b-it` — с 0,939 до 0,892, у `glm-4.7-flash` — с 0,630 до 0,470. У ряда моделей (`qwen3.5-397b-a17b`: $0{,}652 \to 0{,}754$; `qwen3-next-80b`: $0{,}665 \to 0{,}732$) HCR при adaptive растёт — модели активнее пересматривают гипотезы. Таким образом, adaptive-промпт влияет на поведение ревизии гипотез, однако это влияние не транслируется напрямую в рост SR.

2.4.7 Выводы по эксперименту 3

Эксперимент 3 установил: (1) предубеждение подтверждения в индуктивном рассуждении универсально — CTR $\geq 0{,}63$ у всех non-reasoning моделей в baseline; (2) reasoning даёт качественный скачок, недостижимый через prompt engineering: SR `gpt-5.2` reasoning = 0,48 против максимума 0,28 у non-reasoning; (3) adaptive-промпт нестабилен: снижение CTR не конвертируется в рост SR у половины моделей; (4) парадокс `qwen3.5-397b-a17b` — разрыв между стратегией тестирования и качеством обновления гипотез — указывает на то, что предубеждение подтверждения имеет как минимум два независимых компонента: выбор тестируемых троек и ревизию гипотез.

2.5 Сквозной анализ: три парадигмы, девять моделей

2.5.1 Сравнительная таблица результатов по всем экспериментам

Таблица 2.6 представляет агрегированные результаты по всем трём экспериментам для каждой из девяти моделей.

Примечание: delta_bias и fallacy rate — эксперимент 1, чем ниже delta_bias тем лучше; EMA neutral — Formal Logic Neutral при нейтральном промпте, эксперимент 2, чем выше тем лучше; SR base — Success Rate в базовом условии, эксперимент 3, чем выше тем лучше. Таблица отсортирована по delta_bias. `gpt-5.2` reasoning выделен отдельно как режим с принципиально иным типом вывода.

2.5.2 Проверка гипотез о масштабировании и внутрисемейный парадокс

Гипотеза H2 о снижении предубеждений с ростом модели получила частичное подтверждение. На уровне общей тенденции зависимость наблюдается: более мощные модели (`gpt-5.2`, `claude-sonnet-4.6`)

Таблица 2.6 — Сводная таблица результатов по трём экспериментам

Модель	delta_bias (Э1)	fallacy rate (Э1)	EMA neutral (Э2)	SR base (Э3)
qwen3.5-397b-a17b	$-0{,}005$	0,2%	0,764	0,22
glm-4.7-flash	$+0{,}028$	0,8%	0,332	0,04
gemma-3-12b-it	$+0{,}037$	2,7%	0,028	0,06
claude-sonnet-4.6	$+0{,}105$	0,2%	0,790	0,28
deepseek-v3.2	$+0{,}200$	18,7%	0,658	0,10
grok-4.1-fast	$+0{,}249$	22,9%	0,424	0,14
gpt-5.2	$+0{,}375$	40,2%	0,884	0,18
gemma-3-27b-it	$+0{,}498$	58,7%	0,406	0,04
qwen3-next-80b	$+0{,}565$	60,8%	0,772	0,20
gpt-5.2 reasoning	—	—	—	0,38

систематически демонстрируют более низкий уровень предубеждений во всех трёх парадигмах. Однако внутри семейств картина неоднородна.

В семействе Gemma направление эффекта противоречит ожидаемому: `gemma-3-27b-it` демонстрирует несравнимо более высокий токен-bias (delta_bias $= 0{,}498$, fallacy rate $58{,}7\%$), чем `gemma-3-12b-it` (delta_bias $= 0{,}037$, fallacy rate $2{,}7\%$). Это является наиболее ярким проявлением внутрисемейного парадокса масштаба, зафиксированного в эксперименте 1. В семействе Qwen наблюдается противоположный паттерн: `qwen3-next-80b` при меньшем числе активных параметров демонстрирует существенно более высокий bias (delta_bias $= 0{,}565$), чем `qwen3.5-397b-a17b` (delta_bias $= -0{,}005$). Оба семейства указывают на то, что масштаб сам по себе не является надёжным предиктором устойчивости к когнитивным предубеждениям, и подчёркивают роль post-training alignment.

2.5.3 Проверка гипотезы о спектральной природе предубеждений

Гипотеза H3 подтверждена: уровень предубеждений систематически возрастает от эксперимента 1 к эксперименту 3. В задаче Линды в uncorrelated-условии ошибок нет ни у одной модели (все $n_{12} = 0$); в задаче Уэйсона EMA в нейтральном условии при нейтральном промпте не превышает 0,884 даже у лучшей модели, а у `gemma-3-12b-it` падает до 0,028; в задаче 2-4-6 CTR $> 0{,}60$ у всех моделей без исключения. Таким образом, индуктивное открытие правил остаётся наиболее уязвимой к предубеждению подтверждения областью для современных LLM.

2.5.4 Итоги: Proof-of-Concept фреймворка оценки когнитивных предубеждений

Совокупность результатов трёх экспериментов позволяет сформулировать следующие итоговые положения.

Во-первых, когнитивные предубеждения в LLM являются устойчивым, воспроизводимым феноменом. Токен-bias зафиксирован у восьми из девяти моделей в эксперименте 1; предубеждение подтверждения в дедуктивном рассуждении — у всех девяти в эксперименте 2; CTR $\geq 0{,}63$ у всех non-reasoning моделей в эксперименте 3. Гипотеза H1 подтверждена с оговоркой: `qwen3.5-397b-a17b` не проявляет значимого токен-bias в задаче Линды, однако демонстрирует выраженное предубеждение подтверждения в задачах Уэйсона и 2-4-6 (CTR $= 0{,}850$).

Во-вторых, профили предубеждений по экспериментам не коррелируют монотонно. Наглядный пример: `gpt-5.2` имеет высокий токен-bias в задаче Линды (fallacy rate $40{,}2\%$, delta_bias $= 0{,}375$), но лучшую EMA в задаче Уэйсона ($0{,}884$) и наилучший SR в задаче 2-4-6 среди non-reasoning моделей ($0{,}18$, а в reasoning-режиме — $0{,}38$). Это означает, что уязвимость к разным типам предубеждений не является единым латентным фактором, и ни одна агрегированная метрика не заменяет полного профиля.

В-третьих, масштаб модели не является надёжным предиктором устойчивости к предубеждениям. Внутрисемейный парадокс Gemma проявляется по-разному в разных экспериментах: в задаче Линды `gemma-3-27b-it` значительно хуже, чем `gemma-3-12b-it`; в задаче Уэйсона — значительно лучше (EMA $0{,}578$ vs $0{,}106$); в задаче 2-4-6 обе модели слабы (SR $0{,}04$ и $0{,}06$). Это подчёркивает, что post-training alignment оказывает неоднородное воздействие на разные типы рассуждения.

В-четвёртых, reasoning является единственным вмешательством, дающим качественный скачок: SR `gpt-5.2`

reasoning + adaptive (0,48) вдвое превышает лучший non-reasoning результат (0,28). Prompt engineering в форме CoT улучшает результаты только у моделей с достаточной базовой компетентностью и может давать обратный эффект у слабых моделей.

ЗАКЛЮЧЕНИЕ

В заключении подведены итоги проведённого исследования. Разработанная методика применения алгоритмов глубокого обучения для классификации данных показала свою эффективность на тестовых наборах. Проведённый анализ литературы и экспериментальные исследования подтвердили, что предложенный подход позволяет снизить процент ошибок классификации по сравнению с традиционными методами.

Основные выводы работы:

– разработанная методика оправдана с точки зрения теоретических обоснований и практического применения;
– экспериментальные результаты демонстрируют преимущества глубоких нейронных сетей для задач классификации;
– работа содержит рекомендации для дальнейших исследований и внедрения метода в информационные системы.

Таким образом, проведённое исследование подтверждает перспективность использования методов глубокого обучения в решении актуальных задач обработки данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. On the opportunities and risks of foundation models / R. Bommasani, D. A. Hudson, [et al.]. — 2021. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2108.07258.
2. Kahneman D. Thinking, Fast and Slow. — New York : Farrar, Straus, Giroux, 2011.
3. Binz M., Schulz E. Using cognitive psychology to understand GPT-3 // Proceedings of the National Academy of Sciences. — 2023. — Vol. 120, no. 6. — e2218523120.
4. Do large language models show decision heuristics similar to humans? A case study using GPT-3.5 / G. Suri [et al.] // Journal of Experimental Psychology: General. — 2024. — Vol. 153, no. 4. — P. 1066–1075.
5. Macmillan-Scott O., Musolesi M. (Ir)rationality and cognitive biases in large language models // Royal Society Open Science. — 2024. — Vol. 11, no. 6. — P. 240255.
6. Tversky A., Kahneman D. Extensional versus intuitive reasoning: The conjunction fallacy in probability judgment // Psychological Review. — 1983. — Vol. 90, no. 4. — P. 293–315.
7. Wason P. C. Reasoning // New Horizons in Psychology / ed. by B. M. Foss. — Harmondsworth : Penguin, 1966. — P. 135–151.
8. Wason P. C. On the failure to eliminate hypotheses in a conceptual task // Quarterly Journal of Experimental Psychology. — 1960. — Vol. 12, no. 3. — P. 129–140.
9. McNemar Q. Note on the sampling error of the difference between correlated proportions or percentages // Psychometrika. — 1947. — Vol. 12, no. 2. — P. 153–157.
10. Benjamini Y., Hochberg Y. Controlling the false discovery rate: A practical and powerful approach to multiple testing // Journal of the Royal Statistical Society. Series B (Methodological). — 1995. — Vol. 57, no. 1. — P. 289–300.
11. WILT: A multi-turn, memorization-robust inductive logic benchmark for LLMs / E. Banatt [et al.]. — 2024. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2410.10998.
12. Tversky A., Kahneman D. The framing of decisions and the psychology of choice // Science. — 1981. — Vol. 211, no. 4481. — P. 453–458.
13. Chain-of-thought prompting elicits reasoning in large language models / J. Wei [et al.] // Advances in Neural Information Processing Systems. Vol. 35. — 2022. — P. 24824–24837.
14. Nickerson R. S. Confirmation bias: A ubiquitous phenomenon in many guises // Review of General Psychology. — 1998. — Vol. 2, no. 2. — P. 175–220.
15. Tenenbaum J. B. A Bayesian framework for concept learning : PhD thesis / Tenenbaum J. B. — Massachusetts Institute of Technology, 1999.
16. Don’t make your LLM an evaluation benchmark cheater / K. Zhou [et al.]. — 2023. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2311.01964.
17. Language models, like humans, show content effects on reasoning tasks / I. Dasgupta [et al.] // PNAS Nexus. — 2024. — Vol. 3, no. 7. — pgae233.
18. A peek into token bias: Large language models are not yet genuine reasoners / B. Jiang [et al.] // Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. — 2024. — P. 1–15.
19. A corpus and evaluation framework for deeper understanding of commonsense stories / N. Mostafazadeh [et al.]. — 2016. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/1604.01696.
20. Chadimová M., Jurášek E., Kliegr T. Meaningless is better: Hashing bias-inducing words in LLM prompts improves performance in logical reasoning and statistical learning. — 2024. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2411.17304.

21. Arkoudas K. GPT-4 can't reason. — 2023. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2308.03762.

22. Yax N., Anlló H., Palminteri S. Studying and improving reasoning in humans and machines // Communications Psychology. — 2024. — Vol. 2. — P. 51.

23. Will the real Linda please stand up… to large language models? Examining the representativeness heuristic in LLMs / P. Wang [et al.] // Proceedings of the Conference on Language Modeling (COLM 2024). — 2024.

24. A study on the representativeness heuristics problem in large language models / J. Ryu [et al.] // IEEE Access. — 2024. — https://doi.org/10.1109/ACCESS.2024.10706240.

25. Saeedi P., Goodarzi M. GPT's judgements under uncertainty. — 2024. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2410.02820.

26. Cheng P. W., Holyoak K. J. Pragmatic reasoning schemas // Cognitive Psychology. — 1985. — Vol. 17, no. 4. — P. 391–416.

27. Seals S. M., Shalin V. L. Evaluating the deductive competence of large language models // Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics. — 2024. — P. 8606–8622.

28. Evans J. S. B. T. Matching bias in conditional reasoning: Do we understand it after 25 years? // Thinking and Reasoning. — 1998. — Vol. 4, no. 1. — P. 45–82.

29. Bazigaran A., Sohn H. Concept generalization in humans and large language models: Insights from the number game. — 2025. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2512.20162.

30. CogBench: Large language models reason about cognition / J. Coda-Forno [et al.]. — 2024. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2403.09798.

31. Batista R. M., Griffiths T. L. A rational analysis of the effects of sycophantic AI. — 2026. — дата обращения: 01.03.2025. URL: https://arxiv.org/abs/2602.14270.

32. Benchmarking cognitive biases in large language models as evaluators / R. Koo [et al.] // Findings of the Association for Computational Linguistics: ACL 2024. — 2024. — P. 286–311.

33. U.S. Bureau of Labor Statistics. Occupational Employment and Wage Statistics (OEWS). — 2024. — дата обращения: 01.03.2025. URL: https://www.bls.gov/oes/.

34. Cosmides L., Tooby J. Cognitive adaptations for social exchange // The Adapted Mind: Evolutionary Psychology and the Generation of Culture / ed. by J. H. Barkow, L. Cosmides, J. Tooby. — New York : Oxford University Press, 1992. — P. 163–228.

35. Large language models are zero-shot reasoners / T. Kojima [et al.] // Advances in Neural Information Processing Systems. Vol. 35. — 2022. — P. 22199–22213.

36. Wason P. C., Johnson-Laird P. N. Psychology of Reasoning: Structure and Content. — Cambridge : Harvard University Press, 1972.

ПРИЛОЖЕНИЕ. А РУКОВОДСТВО ПО ИСПОЛЬЗОВАНИЮ ШАБЛОНА

В данном приложении приведены примеры оформления основных элементов ВКР согласно требованиям ИТМО (версия 4.0, 2022 г.).

Пример заголовков разделов и подразделов

Ниже показаны три допустимых варианта оформления заголовков (п. 4.4.4 требований ИТМО).

Вариант 1	**Вариант 2**	**Вариант 3**
1 НАЗВАНИЕ РАЗДЕЛА **1.1 Название подраздела** 1.1.1 Название подпункта 1.1.2 Название подпункта	**1 Название раздела** **1.1 Название подраздела** 1.1.1 Название подпункта 1.1.2 Название подпункта	1 Название раздела 1.1 Название подраздела 1.1.1 Название подпункта 1.1.2 Название подпункта

Правила оформления заголовков:

– заголовки разделов и подразделов начинаются с абзацного отступа,
– в конце заголовка точка не ставится,
– переносы слов в заголовках не допускаются,
– аббревиатуры в заголовках не допускаются.

Пример изображения

Ссылка на рисунок обязательна в тексте перед его вставкой (рисунок А.1):

Рисунок А.1 — Пример изображения, вставленного в приложение

Примеры таблиц

Ссылка на таблицу обязательна перед её вставкой (таблица А.1):

Таблица А.1 — Пример построения таблицы

Заголовок	**Заголовок колонки**		**Заголовок колонки**
	Подзаголовок	**Подзаголовок**	
A	B	C	D

Пример таблицы с переносом на следующую страницу (таблица А.2):

Таблица А.2 — Пример переноса таблицы

Заголовок	**Заголовок колонки**	**Заголовок колонки**	**Заголовок колонки**
1	2	3	4
2	3	4	5

Продолжение таблицы А.2

Заголовок	**Заголовок колонки**	**Заголовок колонки**	**Заголовок колонки**
3	4	5	6
4	5	6	7

Примеры перечислений

Вариант 1 — маркированный список через тире (п. 4, Приложение 1 требований ИТМО):

Информационно-сервисная служба для обслуживания удалённых пользователей включает следующие модули:

– удалённый заказ,
– виртуальная справочная служба,
– виртуальный читальный зал.

Вариант 2 — нумерованный список с цифрой и скобкой:

Работа по оцифровке включала следующие технологические этапы:

1) первичный осмотр и структурирование исходных материалов,
2) сканирование документов,
3) обработка и проверка полученных образов,
4) выходной контроль качества.

Вариант 3 — многоуровневый список:

Разрабатываемое устройство можно применять в различных отраслях:

– в машиностроении:
  1) для очистки отливок от формовочной смеси,
  2) для холодной штамповки из листа;
– в ремонте техники:
  1) устранение наслоений на внутренних стенках труб,
  2) очистка каналов небольшого диаметра.

Пример формулы

Функция потерь определяется формулой (А.1):

$$L(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2, \tag{А.1}$$

где y_i — истинное значение, $\hat{y}_i$ — предсказанное значение, n — объём выборки.

Инструкция: Приложение содержит дополнительные материалы, не вошедшие в основной текст работы. В него можно включать изображения, таблицы, программный код, результаты экспериментов и другие вспомогательные данные.